

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ STUDIJŲ PROGRAMA

Srautinio apdorojimo sistemų balansavimas taikant mašininį mokymąsi

Balancing stream processing systems using machine learning

Mokslo tiriamasis darbas II

Atliko:	Vytautas Žilinas	(parašas)
Darbo vadovas:	Partn. doc. Andrius Adamonis	(parašas)
Recenzentas:	Prof. dr. Aistis Raudys	(parašas)

Vilnius – 2020

1. Įvadas

Šio darbo tikslas - apžvelgti susijusius literatūros šaltinius, pateikti jų santraukas ir panaudoti šią informaciją suformuluoti problemą, kuri bus nagrinėjama sekančiame darbe.

Realaus laiko duomenų apdorojimas (angl. real-time data processing) yra jau senai nagrinėjamas kaip vienas iš būdų apdoroti didelių kiekių duomenis (angl. Big data). Vienas iš realaus laiko apdorojimo sprendimų yra srautinis duomenų apdorojimas. Srautinis duomenų apdorojimas (angl. stream processing) – lygiagrečių programų kūrimo modelis, pasireiškiantis sintaksiškai sujungiant nuoseklius skaičiavimo komponentus srautais, kad kiekvienas komponentas galėtų skaičiuoti savarankiškai [Bea15].

Yra keli pagrindiniai srautinio apdorojimo varikliai: „Apache Storm“, „Apache Spark“, „Heron“ ir kiti. „Apache Storm“ ir „Heron“ apdoroja duomenis ne duomenų srautais, o „Apache Spark“ mikro-paketais [KKW⁺15]. „Heron“ srautinio apdorojimo variklis, buvo išleistas „Twitter“ įmonės 2016 metais kaip greitesnė alternatyva „Apache Storm“ srautinio apdorojimo varikliui [Ram16]. Šiame darbe bus naudojamas „Heron“, kadangi tai yra naujesnis ir greitesnis srautinio apdorojimo variklis nei „Apache Storm“ [KBF⁺15].

Srautinio apdorojimo sistemų balansavimas (angl. auto-tuning) - tai sistemos konfigūracijos valdymas siekiant užtikrinti geriausią resursų išnaudojimą - duomenų apdorojimas neprarandant greičio, bet ir naudojant tik reikiamą kiekį resursų. Kadangi srautinio apdorojimo sistemų komponentai yra kuriami kaip lygiagretus skaičiavimo elementai, todėl jie gali būti plečiami horizontaliai ir vertikalčiai [Bea15] keičiant sistemų konfigūraciją. Tačiau lygiagrečių elementų kiekio keitimas nėra vienintelis būdas optimizuoti resursų išnaudojimą. Kiekvienas variklis turi savo rinkinį konfigūruojamų elementų. Darbe naudojamas „Heron“ variklis leidžia optimizuoti sistemas naudojant 56 konfigūruojamus svirtus (angl. levers) [Her19].

Yra skirtingi būdai kaip gali būti parenkama tinkama konfigūracija. Kadangi dar nėra naudojimui paruoštų sprendimų, kurie galėtų balansuoti srautinio apdorojimo sistemas savarankiškai, dažniausiai tai daro duomenų inžinieriai, kurie dirba su šiomis sistemomis. Kadangi srautinio apdorojimo sistemų apkrovos gali būti skirtingų pobūdžių (duomenų kiekis, skaičiavimų sudėtingumas, nereguliari apkrova), o inžinieriai konfigūruodami išbando tik keletą derinių ir pasirenka labiausiai tinkanti [FA17], lieka labai daug skirtingų neišbandytų konfigūracijos variacijų. Optimalios konfigūracijos suradimas yra NP sudėtingumo problema [SSP04], nes žmonėms yra sunku suvokti didelį kiekį konfigūracijos variacijų. Vienas iš būdų automatiškai valdyti konfigūraciją buvo pasiūlytas 2017 metų straipsnyje „Dhalion: self-regulating stream processing in heron“, kuriame autoriai ap-

rašo savo sukurta sprendimą „Dhalion“, kuris konfigūruoja „Heron“ srautinio apdorojimo sistemas pagal esama apkrovą ir resursus, t.y. jei apdorojimo elementų išnaudojimas išauga $>100\%$, „Dhalion“ padidina lygiagrečiai dirbančių apdorojimo elementų kiekį [FAG⁺17]. Tačiau šis sprendimas leidžia reguliuoti tik elementų lygiagretumą ir tai daro tik reaktyviai. Vienas iš naujausių būdų balansuoti srautinio apdorojimo sistemas - mašininis mokymasis. Vienas iš tokių bandymų buvo aprašytas 2018 metų straipsnyje „Auto-tuning Distributed Stream Processing Systems using Reinforcement Learning“, kuriame buvo atliktas tyrimas - „Apache Spark“ sistemos balansavimui buvo naudojamas skatinamojo mokymo REINFORCE algoritmas, kuris pagal dabartinę konfigūraciją ir gaunamas metrikas keitė srautinio apdorojimo sistemos konfigūracijas. Šiame tyrime buvo nustatyta, jog sprendimas, naudojantis mašininių mokymąsi, suranda konfigūraciją per trumpesnę laiką nei žmonės ir taip pat sukurta konfigūraciją naudojančios srautinio apdorojimo sistemos vėlinimas (angl. latency) yra 60-70% mažesnė nei tyrimo metu žmonių sukurtos konfigūracijos [VC18]. Šiame darbe naudojamas „Heron“ variklis leidžia prie savęs prijungti sukurta išorinę metrikų surinkimo programą, kuri gali rinkti tokias sistemų metrikas kaip: naudojama RAM atmintis, CPU apkrova, komponentų paralelizmas ir kitas, kurios bus naudojamos sistemos balansavimui.

Skatinamasis mokymasis yra vienas iš mašininio mokymosi tipų. Šis mokymasis skiriasi nuo kitų, nes nereikia turėti duomenų apmokymui, o programos mokosi darydamos bandymus ir klysdamos. Pagrindinis uždavinys naudojant skatinamąjį mokymąsi yra surasti balansą tarp naujų sprendimų tyrinėjimo (angl. exploration) ir turimos informacijos išnaudojimo (angl. exploitation) [JOA10]. Vienas iš pagrindinių privalumų naudojant skatinamąjį mokymąsi balansavimui - nereikia turėti išankstinių duomenų apmokymui kas leidžia jį paprasčiau pritaikyti skirtingoms srautinio apdorojimo sistemų apkrovoms. Tačiau tokio tipo mašininis mokymasis turi ir problemų: sudėtinga aprašyti tinkamos konfigūracijos apdovanojimo (angl. reward) funkciją ir turi būti teisingai aprašytas balansas tarp tyrinėjimo ir išnaudojimo tam, kad nebūtų patirti nuostoliai [FA17].

Yra sukurta daug skatinamojo mokymosi algoritmų (Monte Carl, Q-learning, Deep Q Network ir kiti), tad šiame darbe jie bus apžvelgti ir vienas iš jų bus pasirinktas ir pritaikytas išsikel tam uždaviniui. Algoritmas bus pasirinktas pagal tai, kuris yra tinkamiausias srautinių apdorojimų sistemų balansavimui.

Numatomas magistro darbo tikslas: Ištirti mašininio mokymosi tinkamumą srautinio apdorojimo sistemų balansavimui.

Numatomi magistro darbo uždaviniai:

1. Apibrėžti duomenų pobūdį ir apkrovas, kurios bus naudojamos eksperimente bei pasirinkti srautinio apdorojimo sistemų metrikas, kurios bus naudojamos eksperimento rezultatų paly-

ginimui.

2. Atlikti literatūros analizę apie esamus skatinamojo mokymosi algoritmus ir pasirinkti vieną iš jų eksperimentui.
3. Sukurti eksperimentinį sprendimą, kuris pritaiko pasirinktą mašininio mokymosi algoritmą srautinio apdorojimo sistemų balansavimui.
4. Atlikti eksperimentą ir palyginti gautus rezultatus su alternatyvomis - „Heron“ su standartine konfigūracija, „Heron“ su „Dhalion“ priedu bei „Heron“ balansavimas pritaikius REINFORCE algoritmą.

1.1. Šio darbo tikslas ir uždaviniai

Tikslas: parengti literatūros apžvalgą, kurioje būtų suformuluota darbe numatoma spręsti problema.


Uždaviniai:

1. Išnagrinėti kaip mokslinėje literatūroje matuojamos srautinio apdorojimo sistemos ir pasirinkti matavimą, kuris bus naudojamas magistro darbe.
2. Išnagrinėti kokius skatinamojo mokymosi algoritmus naudoja kiti autoriai, kokius rezultatus gauna ir pasirinkti algoritmą magistro darbui.

2. Srautinio apdorojimo sistemų matavimas ir derinimas

2.1. Srautinio apdorojimo sistemos

Srautinis duomenų apdorojimas (angl. stream processing) – terminas naudojamas apibrėžti sistemas sudarytas iš skaičiavimo elementų (angl. modules) galinčių skaičiuoti lygiagrečiai ir kurios bendrauja kanalais. Tokios sistemų elementai dažniausiai skirstomi į tris klases: šaltinius (angl. sources) kurie paduoda duomenis į sistemą, filtrus (angl. filters) kurie atlieka tam tikrus vietinius (angl. atomic) skaičiavimus ir nuotakus (angl. sink) kurie perduoda duomenis iš sistemų [Ste97].



1 pav. Srautinio apdorojimo sistemos pavyzdys

Srautinio apdorojimo sistemos literatūroje yra vaizduojamos orientuotais grafkais (1 pav.). Srautinių apdorojimo sistemos skiriasi nuo reliacinių modelio [BBD⁺02]:

- Duomenys į sistemą patenka tinklu, o ne iš fizinių talpyklų.
- Duomenų patekimo tvarka negali būti kontroliuojama.
- Duomenų kiekis yra neapibrėžtas.
- Duomenys apdoroti srautinio apdorojimo sistema yra pašalinami arba archyvuojami, t.y. juos pasiekti yra sunku.

2.1.1. Duomenų vykdymas

Srautinio apdorojimo sistemų veikimui reikalingas srautinio apdorojimo variklis (angl. stream processing engine). Šie varikliai yra skirti srautinio apdorojimo sistemų vykdymui, dislokavimui ir užtikrinti plečiamumą (angl. scaling) ir toleranciją gedimams (angl. fault-tolerance)

[ZGQ⁺17]. Populiariųjų srautinio apdorojimo variklių pavyzdžiai: "Apache Storm", "Apache Heron", "Apache Spark", "Apache Samza" ir t.t [RM19]. Duomenų vykdymas gali būti išskaidytas į tris komponentus [ZGQ⁺17]:

- Planavimas (angl. scheduling) - duomenų apdorojimo užduočių planavimas daro įtaką bendram srautinio apdorojimo veikimui [FY11]. Pavyzdžiui "Apache Samza" naudoja "Apache YARN" resursų valdymo sistemą, kuri turi planavimo posistemę, kuri skirsto resursus [NPP⁺17]
- Plečiamumas (angl. scalability) - apibrėžia daug apdorojimo branduolių turinčios sistemos gebėjimą apdoroti didėjanti kiekį užduočių ir galimybę didinti pačią sistemą kad susidoroti su didėjančių kiekiu duomenų [Bon00]. Srautinio apdorojimo varikliai turi užtikrinti srautinio apdorojimo sistemų plečiamumą [SÇZ05].
- Išskirstytas skaičiavimas (angl. Distributed computation) - tarpusavyje nesusiję skaičiavimo elementai turi naudotojam atrodyti kaip viena darni sistema [TV07]. Srautinio apdorojimo varikliai turi užtikrinti darbų paskirstymą ir skaičiavimo įrenginių koordinaciją, kad daug duomenų būtų apdorjami vienu metu [ZGQ⁺17].

Srautinio apdorojimo sistemos turi viena pagrindinį elementą - srauto procesorių (angl. stream processor), kuris apibrėžia sistemos elementus, aprašo kaip šie sistemos elementai sujungti ir pateikia nustatymus elementams [ZGQ⁺17]. Pavyzdžiui "Apache Storm" šis elementas vadinamas "topology", kuris yra užrašomas Java kalba naudojant "Apache Storm" pateiktą biblioteką [IS15].

2.1.2. Duomenų priėmimas

Į srautinio apdorojimo sistemą duomenis patenka per šaltinius, kurie šiuos duomenis perduoda tolimesniems elementams. Dažniausiai duomenis perduodami į sistemą naudojant žinučių eiles (angl. message queues), nes jos turi buferi, kas leidžia mažinti skirtumus tarp duomenų gavimo ir duomenų apdorojimo greičių, ir žinučių eilių brokeriai gali atfiltruoti duomenis ir nukreipti juos į tinkamus šaltinius [KF16]. Tačiau šaltiniai turi turėti galimybę rinkti išsaugotus ir priimti ateinančius naujus duomenis [SÇZ05], todėl nors ir šaltiniai dažniausiai priima srautinius duomenis, jie turi taip pat gebėti naudoti duomenis iš talpyklų [ZGQ⁺17].

2.2. Srautinio apdorojimo sistemų matavimas

Svarbiausias srautinio apdorojimo sistemų reikalavimas - duomenų apdorojimas ir rezultatų gražinimas turi būti be atsilikimo - didelių apimčių srautiniai duomenys turi būti apdorjami taip

pat greitai kaip ateiną [SÇZ05].

2.2.1. Srautinio apdorojimo sistemų metrikos

Pagrindinės kitų autorių naudojamos metrikos:

- Pralaidumas (angl. Throughput) - per tam tikrą laiko tarpą apdorojamų įvykių kiekis.
todo
- Vėlinimas (angl. Latency) - laiko intervalas nuo apdorojimo arba įvykio pradžios iki apdorojimo pabaigos. Kuo jis mažesnis tuo greitaveiką didesnė.

Vėlinimas ir pralaidumas dažniausiai nepriklauso vienas nuo kito - sistemos, apdorojančios srautus paketais, turi didesnę pralaidumą, tačiau atsiranda papildomas vėlinimas, kai laukiama duomenų paketo apdorojimo pradžios [KRK⁺18].

[SÇZ05] straipsnyje minima, jog srautinio apdorojimo sistemos naudotojas turi išbandyti savo sistemą su tiksliniu darbo krūviu ir išmatuoti pralaidumą ir vėlinimą. [KRK⁺18] lyginą srautinio apdorojimo variklius ir matavimui naudoja vėlinimą, kurį išskaido į įvykio vėlinimą (angl. event-time latency) - laiko intervalas nuo įvykio laiko iki rezultato gavimo iš srautinio apdorojimo sistemos ir apdorojimo vėlinimą (angl. processing-time latency) - laiko intervalas nuo duomens patekimo į srautinio apdorojimo sistemą iki rezultato grąžinimo. Šį skaidymą autoriai daro, nes vertinant sistemas dažnai ignoruojamas įvykio laikas ir gaunamas daug mažesnis vėlinimas negu jis iš tikro yra. Taip pat autoriai išskiria darnų pralaidumą (angl. sustainable throughput) - didžiausia apkrova įvykių, kurią sistema gali apdoroti be pastoviai augančio įvykio vėlinimo, todėl savo eksperimentuose autoriai užtikrina kad duomenų generavimo greitis atitiktų sistemos darnų pralaidumą. Tam kad sužinoti darnų pralaidumą sistemos autoriai pradeda leisti labai didelį srautą duomenų ir mažina iki kol sistemos apdorojimas palaiko generavimo greičius. Visus vėlinimo rezultatus autoriai pateikia maksimalaus pralaidumo apdorojimo ir 90% pralaidumo apdorojimo vidurkiu, minimumu, maksimumu, kvantiliais (90, 95, 99). [HSS⁺14] autoriai nagrinėja srautiniam apdorojimui galimas optimizacijas ir matavimui naudoja normalizuotą pralaidumą (naudojamas vienetas kaip vidurkis), nes tai leidžia lengviau palyginti santykinę greitaveiką. Taip pat [HSS⁺14] pastebi, kad nors ir yra daug metrių, kuriomis galima matuoti optimizaciją: pralaidumas, vėlinimas, paslaugos kokybė (angl. quality of service), energijos ir tinklo panaudojimas, tačiau pagerinus pralaidumą pagerėja ir visos kitos metrikos. [QWH⁺16] srautinių apdorojimo sistemų matavimui naudoja pralaidumą (skaičiuojamą baitais per sekundę) ir vėlinimą, kaip vidurkį nuo duomens patekimo į sistemą iki apdorojimo pabaigos. Taip pat kadangi autoriai lyginą srautinio apdorojimo

variklius jie įveda metriką gedimo toleravimo (angl. fault tolerance) vertinimui, kuriam autoriai išjungia tam tikrą kiekį elementų ir matuoja pralaidumą ir vėlinimą. [ZYL⁺20] palyginimui naudoja sistemos įvykdymo vėlinimą (angl. system completion latency), kuris parodo vidutinį laiko tarpą per kurį kortežas nukeliauja nuo šaltinio iki sistemos galutinio taško. Autoriai skaičiavo vidutinį laiką 5 sekundes intervalais. Taip pat autoriai naudojo matavimui CPU apkrovą kiekvienos instancijos (angl. instance), CPU apkrovą kiekvieno darbinio mazgo (angl. worker node) ir apkrovą tarp instancijų/tarp mazgų, kadangi jų užduotis buvo patobulinti esamą planavimo posistemę. [FAG⁺17] matuoja pralaidumą per minutę. [VC18] tyria labai panašią problemą - srautinių apdorojimo sistemų balansavimą taikant skatinamąjį mokymą ir matavimui naudoja 99 kvantilį vėlinimo. [CDE⁺16] naudoja vėlinimą srautinio apdorojimo variklių vertinimui.

Šaltinis	Vėlinimas	Pralaidumas
[SÇZ05]	Taip	Taip
[KRK ⁺ 18]	Taip	Taip
[HSS ⁺ 14]	Ne	Taip
[QWH ⁺ 16]	Taip	Taip
[ZYL ⁺ 20]	Taip	Ne
[FAG ⁺ 17]	Ne	Taip
[VC18]	Taip	Ne
[CDE ⁺ 16]	Taip	Ne

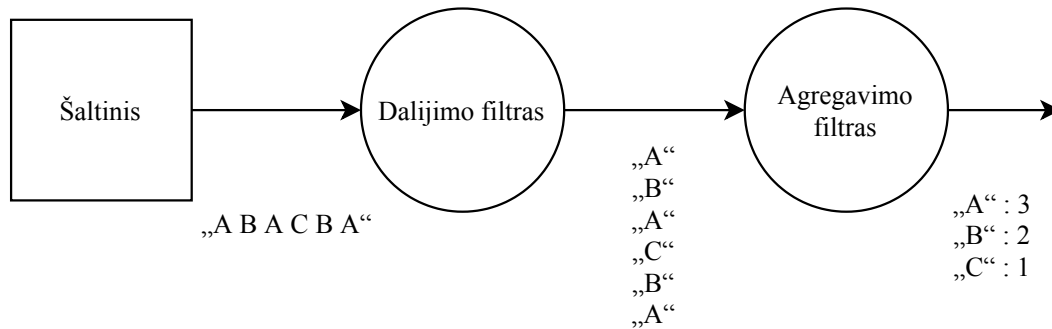
1 lentelė. Metrikos naudojamos tiriant srautinio apdorojimo sistemų greitaveiką

Pagal literatūros analizę (1 len.) matome kad dauguma autorių renkasi vertinti tik pagal vieną metriką ir dažniau matavimui naudojamas vėlinimas. Taip pat [VC18] naudojantis skatinamąjį mokymą matavimui naudoja vėlinimą ir [CDE⁺16] straipsnis, kuris siūlo srautinio apdorojimo sistemų vertinimo sprendimą, naudoja vėlinimą. Todėl magistro darbe vertinimui bus naudojamas vėlinimas.

2.2.2. Srautinio apdorojimo sistemos pobūdis


Srautinio apdorojimo sistemos gali turėti labai skirtingą elementų išsidėstymą ir nuo to priklauso jų greitaveiką. [KRK⁺18] matavimui naudojo du filtrus - agregavimo, kuris skaičiavo visus pirkimus ir jungimo (angl. join) kuris skaičiavo duomenis pagal tam tikrą bendrą rodiklį iš abiejų duomenų srautų. [QWH⁺16] srautinio apdorojimo variklių palyginimui naudoja septynis skirtingus

uždavinius. Vienas iš jų yra WordCount uždavinys, kuris yra plačiai priimtas kaip didelių duomenų apdorojimo sistemos matavimo standartas [HHD⁺10]. Šis uždavinys susidaro iš dviejų elementų: pirmas padalina teksto eilutę į žodžius, antras agreguoja kiekvieno žodžio bendrą skaitiklį ir atnaujina bendrą rezultatą žodžių dažnio, kur raktas tai žodis, o reikšmė tai kiek kartojosi šis žodis (2 pav.).



2 pav. WordCount sistemos pavyzdys

[ZYL⁺20] matavimui naudoja WordCount sistemą, kuri yra paprastesnė, nei 2 pav., nes šaltinis generuoja ir siunčia po vieną žodį ir yra tik agregavimo filtras, ir naudoja SentenceWordCount sistemą, kuri yra identiška 2 pav. pavaizduotai sistemai. Taip pat autoriai sukūrė FileWordCount sistemą, kuri atlieką tą patį kaip ir SentenceWordCount, tačiau šaltinis ne pats generuoja žodžius, o skaito iš tekstinio dokumento ir taip pat naudojo egzistuojančią Yahoo srautinio apdorojimo vertinimą (angl. benchmarking) [CDE⁺16]. [FAG⁺17] naudojo WordCount eksperimentui. [VC18] eksperimentams naudojo Yahoo srautinio apdorojimo palyginimą [CDE⁺16] ir taip pat darė bandymus su realiais daiktų interneto (angl. internet of things) įmonės duomenimis. [CDE⁺16] apibrėžia srautinio apdorojimo sistemą vertinimui skirtingu srautinio apdorojimo variklių. Ši sistemą analizuoja reklamas pagal tipą ir matomumą ir rezultatus deda į Redis duomenų bazę. Sistema sukurta taip, kad aprėptu visas srautinio apdorojimo sistemos savybes (3 pav.).



3 pav. Reklamų analizės sistema [CDE⁺16]

Straipsniai ([FAG⁺17; HHD⁺10; QWH⁺16]) naudojo WordCount (2 pav.), o [CDE⁺16; VC18] naudojo Reklamų analizės srautinę apdorojimo sistemą (3 pav.). Magistro darbe bus daromi tyrimai su Reklamų analizės sistema, kadangi tai yra sukurta sistemą vertinimui ir su WordCount srautinio apdorojimo sistema, kuri neturi pašalinių elementų sistemoje ("Apache Kafka", "Redis").

2.2.3. Srautinio apdorojimo sistemų matavimo duomenys

Vertinant sistemų greitaveiką reikia atsižvelgti ir į testavimui naudojamus duomenis. [KRK⁺18] naudoja žaidimų kūrimo įmonės Rovio duomenis ir naudoja du duomenų srautus - pirmo srautas kur siunčiami kortežai (angl. tuples) susidarantys iš nupirkto valiutos kiekio, laiko ir naudotojo kuris nupirko ir reklamų srautas kuris siunčia nagrinėja valiutos pirkimo siūlymus tam tikru laiku. Generuojami duomenis naudojant normalizuotą paskirstymą ant raktinio lauko. [QWH⁺16] naudoja tekstinius duomenis iš AOL paieškos variklio ir apdoroja juos pagal pasirinktus uždavinius. [ZYL⁺20] matavimui naudoja šaltinių generuojamą tekstą, kadangi lyginamas tas pats srautinio apdorojimo variklis tik su pakeista planavimo posisteme ir naudoja iš anksto sugeneruotą tekstą patalpintą į tekstinį dokumentą. [CDE⁺16] aprašo sistemą kuri daro skirtingų srautinio apdorojimo variklių palyginimus. Šiam vertinimui naudojami duomenys simuliuojantys reklamas. Autoriai naudoja savo duomenų generatorių. Magistro darbe bus naudojami [CDE⁺16] naudojamas duomenų generatorius ir Reklamos analizės sistema. O WordCount srautinės apdorojimo sistemos tyrimui bus naudojami WordCount šaltinio generuojami duomenys.

2.3. Srautinio apdorojimo sistemų derinimas

Sistemų greitaveika yra tiesiogiai susijusi su konfigūravimo parametrais, kurie valdo tokius aspektus kaip atminties valdymas, gijų skaičius, planavimas, resursų valdymas [LCH⁺19]. Taip pat yra išnagrinėta, jog neteisingi nustatymai turi nuostolingus efektus ant sistemos greitaveikos ir stabilumo [HLL⁺11].

[HCL20] išskiria 3 pagrindinius automatinio derinimo iššūkius:

1. Didelė ir sudėtinga parametų erdvė - "Apache Spark" ir "Apache Storm" turi virš 150 konfigūruojamų parametų [BC17; PGT16]. Taip pat kai kurios nustatymų reikšmės, kurios tinka vienam uždaviniui, gali turėti neigiamos įtakos kitam [HLL⁺11; JC16].
2. Sistemų mastas ir sudėtingumas - Sistemų administratoriai turi gebėti konfigūruoti didelius kiekius skaičiavimo mazgų, kurie gali skirtis CPU, atmintimi, tinklo tipais [HCL20].
3. Pradinių duomenų statistikos trūkumas - įvedimo duomenys srautinėse apdorojimo sistemose yra realus srautai, kurie stipriai varijuoja savo apimtimi [DP18].

[TLW17] nagrinėjantis tinkamos konfigūracijos radimą naudojant genetinius algoritmus "Apache Storm" srautinio apdorojimo sistemoms nustatė, jog lygiagretumo laipsnis labiausiai daro įtaką srautinio apdorojimo sistemų greitaveikai. "Apache Heron" yra srautinio apdorojimo variklis, kuris sukurtas pagal "Apache Storm" su patobulinimais [KBF⁺15] pateikia naują būdą kontroliuoti srautą - priešslėgis (angl. backpressure), kuris leidžia filtrui sulėtinti prieš jį einantį elementą, kas leidžia sumažinti vėlinimą ir taip pat gali būti naudojamas kaip greitaveikos praradimo indikatorius [BCB⁺18]. Taip pat [BCB⁺18] nagrinėja "Apache Heron" automatinį konfigūravimą naudojant iš anksto aprašytas taisykles.

3. Mašininis mokymasis

3.1. Mašininis mokymasis srautinių sistemų derinimui

[HCL20] aprašo skirtingus sprendimus automatiniam konfigūravimui ir išskiria šiuos mašininio mokymosi privalumus:

- Nebūtina suprasti sistemos, užduočių ir duomenų, kadangi naudojamas juodos dėžės (angl. black-box) principas.
- Mašininio mokymosi modelis pats save tobulina, kuo daugiau gauna duomenų.

Šio straipsnio autoriai išskiria mašininio mokymosi iššūkius :

- Parametrų parinkimas - kadangi konfigūruojamų parametrų kiekis yra didelis [BC17; PGT16] ne visi iš jų stipriai daro įtaką greitaveikai, todėl pirma išsirinkti aktualiausius parametrus resursų valdymo, užduočių planavimo ir duomenų valdymo. Tam dažnai naudojama eksperto pagalba [WXH16], gidai arba eksperimentavimo pagalba. Tačiau galima ir naudoti mašininio mokymosi algoritmą, kad nustatyti koreliacija tarp parametrų ir greitaveikos [YLL⁺12; VC18]
- Mašininio mokymosi modelio pasirinkimas - kadangi yra nemažai skirtingų mašininio mokymosi metodų kurie tinka derinimo uždaviniui.

Taip pat pateikiami pavyzdžiai paketinio apdorojimo ir srautinio apdorojimo derinimo naudojant mašininį mokymąsi straipsniai (3 lentelėje pateikiami tik išrinkti srautinio apdorojimo pavyzdžiai).

Šaltinis	Įvesties savybės	Mašininio mokymosi metodai
Zacheilas et al. [ZKZ ⁺ 15]	Rinkinys kelių konfigūracijos parametrų	Gaussian Processes
Li et al. [LTX16]	Atminties dydžiai ir branduolių ir gijų kiekis skirtingose stadijose	Support Vector Regression
Trotter et al. [TLW17]	Darbinių procesų kiekis, vykdytojų kiekis	Genetic Algorithm, Bayesian Optimization
Trotter et al. [TWH19]	Vykdytojai, šaltinių ir filtrų lygiagretumas, acker lygiagretumas	Genetic Algorithm, Support Vector Machines
OrientStream [WMG ⁺ 17]	Įvairios duomenų, plano, filtrų ir klas-terio lygio savybės	Ensemble/ Incremental ML
Vaquero et al. [VC18]	Parametrai ir metrikos parinkti faktori-nės analizės (angl. factor analysis) pa-galba	Reinforcement Learning

2 lentelė. Srautinių sistemų derinimo naudojant mašininių mokymąsi pavyzdžiai [HCL20]

3.2. Skatinamais mokymasis srautiniam apdorojimui

[VC18] nagrinėja srautinių sistemų derinimą naudojant skatinamąjį mokymąsi. Autoriai pirmą pasirenka Lasso path analysis algoritmą, kurio pagalba atlieka parametrų atranka, kad išrinktų svarbiausius parametrus pasirinktos metrikos valdymui. Konfigūracijos valdymui pasirinktas modifikuotas REINFORCE algoritmas. Atliktas eksperimentas su "Apache Spark" ir sumažino vėlinimą 60-70%.

[NLY⁺19] nagrinėja resursų valdymo problemą srautinio apdorojimo sistemose ir siūlo sprendimą naudojanči skatinamąjį mokymą, kuris daro optimizacijas pagal srautinės apdorojimo sistemos grafus. Eksperimentas atliekamas naudojant REINFORCE [Wil92] algoritmą su Adam optimizacijos funkcija [KB14] ir naudojama savo parašytą srautinio apdorojimo variklį.

[LXT⁺18] nagrinėja planavimo problemos (apkrovos paskirstymas darbiniais elementais) sprendimą naudojant skatinamąjį mokymąsi. Autoriai siūlo naudoti Actor-Critic lillie-

rap2015continuous metodą naudojant Deep Q Learning [MKS⁺15] tinklą kaip Actor ir Gilųjį neuro-
ninių tinklą kaip Critic. Autorių rezultatai rodo 45% greitaveikos padidėjimą palyginus su integruotą
"Apache Storm" planavimo posistemę.

[RCP19] nagrinėja srautinių sistemų dislokavimą naudojant skatinamąjį mokymą. Sprendžiama problema dislokavimo valdymo su skirtingų skaičiavimo mazgų. Naudojamas Q Learning algoritmas su įvairioms modifikacijom (kombinuojama su tiksliais modeliais). Autoriai matuoja dislokavimo tikslumą ir konvergavimo greitį.

Šaltinis	Skatinamojo mokymosi algoritmas
[VC18]	Adaptuotas REINFORCE [Wil92]
[NLY ⁺ 19]	REINFORCE [Wil92] su Adam optimizacijos funkcija [KB14]
[LXT ⁺ 18]	Deep Q Learning [MKS ⁺ 15] ir Actor–Critic [LHP ⁺ 15]
[RCP19]	Q-learning [MKS ⁺ 15] su papildomomis funkcijomis

3 lentelė. Skatinamojo mokymosi naudojimas

4. Rezultatai ir Išvados

4.1. Rezultatai

1. Išnagrinėta mokslinė literatūra aprašanti srautinio apdorojimo problemas ir parengtos rekomendacijos magistro darbe srautinių sistemų pobūdžiui, eksperimento duomenims ir vertinamoms metrikoms.
2. Išnagrinėta mokslinė literatūra aprašanti skatinamųjų algoritmų panaudojimą srautinio apdorojimo srityje ir pasirinktas algoritmas, kurį ketinama naudoti magistro darbe.

4.2. Išvados

1. Išnagrinėjus literatūrą magistro darbe ketinama naudoti:
 - Reklamos analizės sistema, kadangi tai yra priimtas vertinimo standartas srautinio apdorojimo sistemoms ir WordCount sistema, kadangi tai ji neturi pašalinių elementų ir yra naudojama kituose moksliniuose darbuose.
 - Reklamos analizės sistemos bandymui naudoti [CDE⁺16] duomenų generatorius, kuris yra pateikiamas su vertinimu, o WordCount sistema naudos savo šaltinį kaip duomenų generavimo elementą.
 - Sprendimams palyginti naudoti vėlinimą, kadangi [CDE⁺16] naudoja tai kaip pagrindinį vertinimo kriterijų lyginant srautinio apdorojimo variklius ir kiti autoriai naudoja savo eksperimentuose.
2. Magistro darbui ketinama pasirinkti Deep Q Learning ir Actor-Critic atsižvelgus į šio algoritmo naujumą ir jo tinkamumą nagrinėti pastovaus valdymo uždavinį [SLH⁺14]. Taip pat atsižvelgus į [HCL20; VC18] rezultatus ketinama atlikti bandymus su sumažinta konfigūruojamų elementų aibe naudojant parametrų parinkimą, atlikti bandymus su nekeista elementų aibe ir palyginti rezultatus.

Literatūra

- [BBD⁺02] Brian Babcock, Shivnath Babu, Mayur Datar, Rajeev Motwani ir Jennifer Widom. Models and issues in data stream systems. *Proceedings of the twenty-first ACM SIGMOD-SIGACT-SIGART symposium on Principles of database systems*, p. 1–16, 2002.
- [BC17] Muhammad Bilal ir Marco Canini. Towards automatic parameter tuning of stream processing systems. P. 189–200, 2017-09. DOI: 10.1145/3127479.3127492.
- [BCB⁺18] Manu Bansal, Eyal Cidon, Arjun Balasingam, Aditya Gudipati, Christos Kozyrakis ir Sachin Katti. Trevor: automatic configuration and scaling of stream processing pipelines, 2018. arXiv: 1812.09442 [cs.DC].
- [Bea15] Jonathan Beard. A short intro to stream processing. <http://www.jonathanbeard.io/blog/2015/09/19/streaming-and-dataflow.html>, 2015-09.
- [Bon00] André B Bondi. Characteristics of scalability and their impact on performance. *Proceedings of the 2nd international workshop on Software and performance*, p. 195–203, 2000.
- [CDE⁺16] S. Chintapalli, D. Dagit, B. Evans, R. Farivar ir k.t. Benchmarking streaming computation engines: storm, flink and spark streaming. *2016 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW)*, p. 1789–1792, 2016.
- [DP18] Miyuru Dayarathna ir Srinath Perera. Recent advancements in event processing. *ACM Comput. Surv.*, 51(2), 2018-02. ISSN: 0360-0300. DOI: 10.1145/3170432.
- [FA17] Avrilia Floratou ir Ashvin Agrawal. Self-regulating streaming systems: challenges and opportunities. *Proceedings of the International Workshop on Real-Time Business Intelligence and Analytics, BIRTE '17*, 1:1–1:5, Munich, Germany. ACM, 2017. ISBN: 978-1-4503-5425-7. DOI: 10.1145/3129292.3129295. URL: <http://doi.acm.org/10.1145/3129292.3129295>.
- [FAG⁺17] Avrilia Floratou, Ashvin Agrawal, Bill Graham, Sriram Rao ir Karthik Ramasamy. Dhalion: self-regulating stream processing in heron. *Proceedings of the VLDB Endowment*, 10:1825–1836, 2017-08. DOI: 10.14778/3137765.3137786.
- [FY11] Zbynek Falt ir Jakub Yaghob. Task scheduling in data stream processing. *DATESO*, p. 85–96, 2011.

- [HCL20] Herodotos Herodotou, Yuxing Chen ir Jiaheng Lu. A survey on automatic parameter tuning for big data processing systems. *ACM Computing Surveys (CSUR)*, 53(2):1–37, 2020.
- [Her19] Heron. Heron documentation on cluster configuration. <http://heron.incubator.apache.org/docs/cluster-config-overview/>, 2019.
- [HHD⁺10] Shengsheng Huang, Jie Huang, Jinquan Dai, Tao Xie ir Bo Huang. The hibenxh benchmark suite: characterization of the mapreduce-based data analysis. *2010 IEEE 26th International Conference on Data Engineering Workshops (ICDEW 2010)*, p. 41–51. IEEE, 2010.
- [HLL⁺11] Herodotos Herodotou, Harold Lim, Gang Luo, Nedyalko Borisov, Liang Dong, Fatma Bilgen Cetin ir Shivnath Babu. Starfish: a self-tuning system for big data analytics. *Cidr*, tom. 11 numeris 2011, p. 261–272, 2011.
- [HSS⁺14] Martin Hirzel, Robert Soulé, Scott Schneider, Buğra Gedik ir Robert Grimm. A catalog of stream processing optimizations. *ACM Computing Surveys (CSUR)*, 46(4):1–34, 2014.
- [YLL⁺12] Hailong Yang, Zhongzhi Luan, Wenjun Li, Depei Qian ir Gang Guan. Statistics-based workload modeling for mapreduce. *2012 IEEE 26th International Parallel and Distributed Processing Symposium Workshops & PhD Forum*, p. 2043–2051. IEEE, 2012.
- [IS15] Muhammad Hussain Iqbal ir Tariq Rahim Soomro. Big data analysis: apache storm perspective. *International journal of computer trends and technology*, 19(1):9–14, 2015.
- [JC16] Pooyan Jamshidi ir Giuliano Casale. An uncertainty-aware approach to optimal configuration of stream processing systems. *CoRR*, abs/1606.06543, 2016. eprint: 1606.06543.
- [JOA10] Thomas Jaksch, Ronald Ortner ir Peter Auer. Near-optimal regret bounds for reinforcement learning. *J. Mach. Learn. Res.*, 11:1563–1600, 2010-08. issn: 1532-4435. URL: <http://dl.acm.org/citation.cfm?id=1756006.1859902>.
- [KB14] Diederik P. Kingma ir Jimmy Ba. Adam: a method for stochastic optimization, 2014. arXiv: 1412.6980 [cs.LG].

- [KBF⁺15] Sanjeev Kulkarni, Nikunj Bhagat, Maosong Fu, Vikas Kedigehalli, Christopher Kellogg, Sailesh Mittal, Jignesh M. Patel, Karthik Ramasamy ir Siddarth Taneja. Twitter heron: stream processing at scale. *Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data*, SIGMOD '15, p. 239–250, Melbourne, Victoria, Australia. ACM, 2015. ISBN: 978-1-4503-2758-9. DOI: 10.1145/2723372.2742788. URL: <http://doi.acm.org/10.1145/2723372.2742788>.
- [KF16] Supun Kamburugamuve ir Geoffrey Fox. Survey of distributed stream processing. *Bloomington: Indiana University*, 2016.
- [KKW⁺15] Holden Karau, Andy Konwinski, Patrick Wendell ir Matei Zaharia. *Learning spark: lightning-fast big data analysis*. ” O'Reilly Media, Inc.”, 2015.
- [KRK⁺18] Jeyhun Karimov, Tilmann Rabl, Asterios Katsifodimos, Roman Samarev, Henri Heiskanen ir Volker Markl. Benchmarking distributed stream processing engines. *ArXiv*, abs/1802.08496, 2018.
- [LCH⁺19] Jiaheng Lu, Yuxing Chen, Herodotos Herodotou ir Shivnath Babu. Speedup your analytics: automatic parameter tuning for databases and big data systems. *Proceedings of the VLDB Endowment*, 12(12):1970–1973, 2019.
- [LHP⁺15] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver ir Daan Wierstra. Continuous control with deep reinforcement learning, 2015. arXiv: 1509.02971 [cs.LG].
- [LTX16] Teng Li, Jian Tang ir Jielong Xu. Performance modeling and predictive scheduling for distributed stream data processing. *IEEE Transactions on Big Data*, 2(4):353–364, 2016.
- [LXT⁺18] Teng Li, Zhiyuan Xu, Jian Tang ir Yanzhi Wang. Model-free control for distributed stream data processing using deep reinforcement learning. *Proc. VLDB Endow.*, 11(6):705–718, 2018-02. ISSN: 2150-8097. DOI: 10.14778/3199517.3199521. URL: <https://doi.org/10.14778/3199517.3199521>.
- [MKS⁺15] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu ir k.t. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

- [NLY⁺19] Xiang Ni, Jing Li, Mo Yu, Wang Zhou ir Kun-Lung Wu. Generalizable resource allocation in stream processing via deep reinforcement learning, 2019. arXiv: 1911.08517 [cs.LG].
- [NPP⁺17] Shadi A Noghabi, Kartik Paramasivam, Yi Pan, Navina Ramesh, Jon Bringham, Indranil Gupta ir Roy H Campbell. Samza: stateful scalable stream processing at linkedin. *Proceedings of the VLDB Endowment*, 10(12):1634–1645, 2017.
- [PGT16] Panagiotis Petridis, Anastasios Gounaris ir Jordi Torres. Spark parameter tuning via trial-and-error, 2016. arXiv: 1607.07348 [cs.DC].
- [QWH⁺16] S. Qian, G. Wu, J. Huang ir T. Das. Benchmarking modern distributed streaming platforms. *2016 IEEE International Conference on Industrial Technology (ICIT)*, p. 592–598, 2016.
- [Ram16] Karthik Ramasamy. Open sourcing twitter heron, 2016.
- [RCP19] Gabriele Russo Russo, Valeria Cardellini ir Francesco Lo Presti. Reinforcement learning based policies for elastic stream processing on heterogeneous resources. *Proceedings of the 13th ACM International Conference on Distributed and Event-Based Systems, DEBS '19*, p. 31–42, Darmstadt, Germany. Association for Computing Machinery, 2019. ISBN: 9781450367943. DOI: 10.1145/3328905.3329506. URL: <https://doi.org/10.1145/3328905.3329506>.
- [RM19] Henriette Röger ir Ruben Mayer. A comprehensive survey on parallelization and elasticity in stream processing. *ACM Computing Surveys (CSUR)*, 52(2):1–37, 2019.
- [SÇZ05] Michael Stonebraker, Uğur Çetintemel ir Stan Zdonik. The 8 requirements of real-time stream processing. *ACM Sigmod Record*, 34(4):42–47, 2005.
- [SLH⁺14] David Silver, Guy Lever, Nicolas Heess, Thomas Degris, Daan Wierstra ir Martin Riedmiller. Deterministic policy gradient algorithms. *Proceedings of the 31st International Conference on International Conference on Machine Learning - Volume 32, ICML'14*, p. I–387–I–395, Beijing, China. JMLR.org, 2014.
- [SSP04] David G. Sullivan, Margo I. Seltzer ir Avi Pfeffer. Using probabilistic reasoning to automate software tuning. *SIGMETRICS Perform. Eval. Rev.*, 32(1):404–405, 2004–06. ISSN: 0163-5999. DOI: 10.1145/1012888.1005739. URL: <http://doi.acm.org/10.1145/1012888.1005739>.

- [Ste97] Robert Stephens. A survey of stream processing. *Acta Informatica*, 34(7):491–541, 1997.
- [TLW17] M. Trotter, G. Liu ir T. Wood. Into the storm: descrying optimal configurations using genetic algorithms and bayesian optimization. *2017 IEEE 2nd International Workshops on Foundations and Applications of Self* Systems (FAS*W)*, p. 175–180, 2017.
- [TV07] Andrew S Tanenbaum ir Maarten Van Steen. *Distributed systems: principles and paradigms*. Prentice-Hall, 2007.
- [TWH19] Michael Trotter, Timothy Wood ir Jinho Hwang. Forecasting a storm: divining optimal configurations using genetic algorithms and supervised learning. *2019 IEEE International Conference on Autonomic Computing (ICAC)*, p. 136–146. IEEE, 2019.
- [VC18] Luis M. Vaquero ir Felix Cuadrado. Auto-tuning distributed stream processing systems using reinforcement learning, 2018. arXiv: 1809.05495 [cs.DC].
- [Wil92] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine learning*, 8(3-4):229–256, 1992.
- [WMG⁺17] Chunkai Wang, Xiaofeng Meng, Qi Guo, Zujian Weng ir Chen Yang. Automating characterization deployment in distributed data stream management systems. *IEEE Transactions on Knowledge and Data Engineering*, 29(12):2669–2681, 2017.
- [WXH16] Guolu Wang, Jungang Xu ir Ben He. A novel method for tuning configuration parameters of spark based on machine learning. *2016 IEEE 18th International Conference on High Performance Computing and Communications; IEEE 14th International Conference on Smart City; IEEE 2nd International Conference on Data Science and Systems (HPCC/SmartCity/DSS)*, p. 586–593. IEEE, 2016.
- [ZGQ⁺17] Xinwei Zhao, Saurabh Garg, Carlos Queiroz ir Rajkumar Buyya. A taxonomy and survey of stream processing systems. *Software Architecture for Big Data and the Cloud*, p. 183–206. Elsevier, 2017.
- [ZYL⁺20] Yitian Zhang, Jiong Yu, Liang Lu, Ziyang Li ir Zhao Meng. L-heron: an open-source load-aware online scheduler for apache heron. *Journal of Systems Architecture*, 106:101727, 2020.
- [ZKZ⁺15] Nikos Zacheilas, Vana Kalogeraki, Nikolas Zygouras, Nikolaos Panagiotou ir Dimitrios Gunopulos. Elastic complex event processing exploiting prediction. *2015 IEEE International Conference on Big Data (Big Data)*, p. 213–222. IEEE, 2015.