

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ STUDIJŲ PROGRAMA

Srautinio apdorojimo sistemų balansavimas taikant mašininį mokymąsi

Balancing stream processing systems using machine learning

Mokslo tiriamasis darbas II

Atliko:	Vytautas Žilinas	(parašas)
Darbo vadovas:	Partn. doc. Andrius Adamonis	(parašas)
Recenzentas:	Prof. dr. Aistis Raudys	(parašas)

Vilnius – 2020

TURINYS

ĮVADAS	3
1. SRAUTINIO APDOROJIMO SISTEMŲ MATAVIMAS IR DERINIMAS	6
1.1. Srautinio apdorojimo sistemos	6
1.1.1. Duomenų vykdymas	6
1.1.2. Duomenų priėmimas	7
1.2. Srautinio apdorojimo sistemų matavimas	7
1.2.1. Srautinio apdorojimo sistemų metrikos	8
1.2.2. Srautinio apdorojimo sistemos pobūdis	9
1.2.3. Srautinio apdorojimo sistemų matavimo duomenys	11
1.3. Srautinio apdorojimo sistemų derinimas	12
2. MAŠININIS MOKYMASIS	13
2.1. Mašininis mokymasis srautinio apdorojimo sistemų derinimui	13
2.2. Skatinamasis mokymasis srautiniam apdorojimui	14
IŠVADOS	16
LITERATŪRA	17

Įvadas

Šio darbo tikslas – apžvelgti susijusius literatūros šaltinius, pateikti jų santraukas ir panaudoti šią informaciją suformuluoti problemą, kuri bus nagrinėjama sekančiame darbe.

Realaus laiko duomenų apdorojimas (angl. real-time data processing) yra jau senai nagrinėjamas kaip vienas iš būdų apdoroti didelių kiekių duomenis (angl. Big data). Vienas iš realaus laiko apdorojimo sprendimų yra srautinis duomenų apdorojimas. Srautinis duomenų apdorojimas (angl. stream processing) – lygiagrečių programų kūrimo modelis, pasireiškiantis sintaksiškai sujungiant nuoseklius skaičiavimo komponentus srautais, kad kiekvienas komponentas galėtų skaičiuoti savarankiškai [Bea15].

Yra keli pagrindiniai srautinio apdorojimo varikliai: „Apache Storm“, „Apache Spark“, „Heron“ ir kiti. „Apache Storm“ ir „Heron“ apdoroja duomenis duomenų srautais, o „Apache Spark“ mikro–paketais [KKW⁺15]. „Heron“ srautinio apdorojimo variklis, buvo išleistas „Twitter“ įmonės 2016 metais kaip patobulinta alternatyva „Apache Storm“ srautinio apdorojimo varikliui [Ram16]. Šiame darbe bus naudojamas „Heron“, kadangi tai yra naujesnis ir greitesnis srautinio apdorojimo variklis nei „Apache Storm“ [KBF⁺15].

Srautinio apdorojimo sistemų balansavimas (angl. auto-tuning) – tai sistemos konfigūracijos valdymas siekiant užtikrinti geriausią resursų išnaudojimą – duomenų apdorojimas neprarandant greičio, bet ir naudojant tik reikiamą kiekį resursų. Kadangi srautinio apdorojimo sistemų komponentai yra kuriami kaip lygiagretus skaičiavimo elementai, todėl jie gali būti plečiami horizontaliai ir vertikalčiai [Bea15] keičiant sistemų konfigūraciją. Tačiau lygiagrečių elementų kiekio keitimas nėra vienintelis būdas optimizuoti resursų išnaudojimą. Kiekvienas variklis turi savo rinkinį konfigūruojamų elementų. Darbe naudojamas „Heron“ variklis leidžia optimizuoti sistemas naudojant 56 konfigūruojamus parametrus [Her19].

Yra skirtingi būdai kaip gali būti parenkama tinkama konfigūracija. Kadangi dar nėra naudojimui paruoštų sprendimų, kurie galėtų balansuoti srautinio apdorojimo sistemas savarankiškai, dažniausiai už tai yra atsakingi inžinieriai, kurie dirba su šiomis sistemomis. Kadangi srautinio apdorojimo sistemų apkrovos gali būti skirtingų pobūdžių (duomenų kiekis, skaičiavimų sudėtingumas, nereguliari apkrova), o inžinieriai konfigūruodami išbando tik kelis derinius ir pasirenka labiausiai tinkanti [FA17], lieka labai daug skirtingų neišbandytų konfigūracijos variacijų. Optimalios konfigūracijos suradimas yra NP sudėtingumo problema [SSP04], kadangi žmonėms yra sunku suvokti didelį kiekį konfigūracijos variacijų. Vienas iš būdų automatiškai valdyti konfigūraciją buvo pasiūlytas 2017 metų straipsnyje „Dhalion: self-regulating stream processing in heron“,

kuriame autoriai aprašo savo sukurtą sprendimą „Dhalion“, kuris konfigūruoja „Heron“ srautinio apdorojimo sistemas pagal esamą apkrovą ir turimus resursus, t.y. jei apdorojimo elementų išnaudojimas išauga $>100\%$, „Dhalion“ padidina lygiagrečiai dirbančių apdorojimo elementų kiekį [FAG⁺17]. Tačiau šis sprendimas leidžia reguliuoti tik elementų lygiagretumą ir tai daro tik reaktyviai. Vienas iš naujausių būdų balansuoti srautinio apdorojimo sistemas – mašininis mokymasis. Vienas iš tokių bandymų aprašytas 2018 metų straipsnyje „Auto-tuning Distributed Stream Processing Systems using Reinforcement Learning“, kuriame atliktas tyrimas – „Apache Spark“ sistemos balansavimui naudojamas skatinamojo mokymo REINFORCE algoritmas, kuris, pagal dabartinę konfigūraciją ir renkamąs metrikas, keičia srautinio apdorojimo sistemos konfigūracijos parametrus. Šiame tyrime nustatyta, jog sprendimas, naudojantis mašininį mokymąsi, suranda optimalesnę konfigūraciją per trumpesnę laiką nei žmonės ir taip pat surastą konfigūraciją naudojančios srautinio apdorojimo sistemos vėlinimas (angl. latency) yra 60–70% mažesnis nei tyrimo metu ekspertų derinamos konfigūracijos [VC18]. Šiame darbe naudojamas „Heron“ variklis leidžia prisijungti sukurtą išorinę metrikų surinkimo programą, kuri gali rinkti tokias sistemų metrikas kaip: naudojama RAM atmintis, CPU apkrova, komponentų paralelizmas ir kitas, kurios gali būti naudojamos balansavimui.

Skatinamasis mokymasis yra vienas iš mašininio mokymosi tipų. Šis mokymasis skiriasi nuo kitų, nes nereikia turėti duomenų apmokymui, o programos mokosi darydamos bandymus ir klysdamos. Pagrindinis uždavinys naudojant skatinamąjį mokymąsi – surasti balansą tarp naujų sprendimų tyrinėjimo (angl. exploration) ir turimos informacijos išnaudojimo (angl. exploitation) [JOA10]. Vienas iš pagrindinių privalumų naudojant skatinamąjį mokymąsi balansavimui – nereikia turėti išankstinių duomenų apmokymui kas leidžia jį paprasčiau pritaikyti skirtingoms srautinio apdorojimo sistemų apkrovoms. Tačiau tokio tipo mašininis mokymasis turi ir problemų: sudėtinga aprašyti tinkamos konfigūracijos apdovanojimo (angl. reward) funkciją ir balansą tarp tyrinėjimo ir išnaudojimo tam, kad nebūtų patiriami nuostoliai [FA17].

Yra sukurta daug skatinamojo mokymosi algoritmų (Monte Carlo, Q-learning, Deep Q Network ir kiti), šiame darbe jie bus apžvelgti ir vienas iš jų bus pasirinktas ir pritaikytas išsikeltam uždaviniui.

Numatomas magistro darbo tikslas: Ištirti mašininio mokymosi tinkamumą srautinio apdorojimo sistemų balansavimui.

Numatomi magistro darbo uždaviniai:

1. Apibrėžti duomenų pobūdį ir apkrovas, kurios bus naudojamos eksperimente bei pasirinkti srautinio apdorojimo sistemų metrikas, kurios bus naudojamos eksperimento rezultatų paly-

ginimui.

2. Atlikti literatūros analizę apie esamus skatinamojo mokymosi algoritmus ir pasirinkti vieną iš jų eksperimentui.
3. Sukurti eksperimentinį sprendimą, kuris pritaiko pasirinktą mašininio mokymosi algoritmą srautinio apdorojimo sistemų balansavimui.
4. Atlikti eksperimentą ir palyginti gautus rezultatus su alternatyvomis – „Heron“ su standartine konfigūracija, „Heron“ su „Dhalion“ priedu bei „Heron“ balansavimas pritaikius REINFORCE algoritmą.

Šio darbo tikslas ir uždaviniai

Tikslas: parengti literatūros apžvalgą, kurioje būtų suformuluota darbe numatoma spręsti problema.


Uždaviniai:

1. Išnagrinėti kaip mokslinėje literatūroje matuojamos srautinio apdorojimo sistemos ir parengti rekomendaciją matavimui, kuris tinkamas naudojamas magistro darbe.
2. Išnagrinėti kokius skatinamojo mokymosi algoritmus naudoja kiti autoriai, kokius rezultatus gauna ir pateikti algoritmą ketinama naudoti magistro darbui.

1. Srautinio apdorojimo sistemų matavimas ir derinimas

1.1. Srautinio apdorojimo sistemos

Srautinis duomenų apdorojimas (angl. stream processing) – terminas naudojamas apibrėžti sistemas sudarytas iš skaičiavimo elementų (angl. modules) galinčių skaičiuoti lygiagrečiai ir kurios bendrauja kanalais. Tokių sistemų elementai dažniausiai skirstomi į tris klases: šaltinius (angl. sources), kurie paduoda duomenis į sistemą, filtrus (angl. filters), kurie atlieka tam tikrus vieningus (angl. atomic) skaičiavimus ir nuotakus (angl. sink), kurie perduoda duomenis iš sistemų [Ste97].



1 pav. Srautinio apdorojimo sistemos pavyzdys

Srautinio apdorojimo sistemos literatūroje yra vaizduojamos orientuotais grafkais (1 pav.). Srautinio apdorojimo sistemos skiriasi nuo reliacinių modelių šiais aspektais [BBD⁺02]:

- Duomenys į sistemą patenka tinklu, o ne iš fizinių talpyklų.
- Duomenų patekimo tvarka negali būti kontroliuojama.
- Duomenų kiekis yra neapibrėžtas.
- Duomenys apdoroti srautinio apdorojimo sistema yra pašalinami arba archyvuojami, t.y. juos pasiekti yra sunku.

1.1.1. Duomenų vykdymas

Srautinio apdorojimo sistemų veikimui reikalingas srautinio apdorojimo variklis (angl. stream processing engine). Šie varikliai yra skirti srautinio apdorojimo sistemų vykdymui, dislokavimui, plečiamumo (angl. scaling) užtikrinimui ir gedimų tolerancijai (angl. fault-tolerance)

[ZGQ⁺17]. Populiariųjų srautinio apdorojimo variklių pavyzdžiai: „Apache Storm“, „Apache Heron“, „Apache Spark“, „Apache Samza“ ir t.t [RM19]. Duomenų vykdymas gali būti išskaidytas į tris elementus [ZGQ⁺17]:

- Planavimas (angl. scheduling) – duomenų apdorojimo užduočių planavimas daro įtaką bendram srautinio apdorojimo sistemos veikimui [FY11]. Pavyzdžiui, „Apache Samza“ naudoja „Apache YARN“ resursų valdymo sistemą, kuri turi planavimo posistemę, kuri skirsto resursus [NPP⁺17]
- Plečiamumas (angl. scalability) – apibrėžia daug apdorojimo branduolių turinčios sistemos gebėjimą apdoroti didėjanti kiekį užduočių ir galimybę didinti pačią sistemą, kad ji galėtų susidoroti su didėjančiu kiekiu duomenų [Bon00]. Srautinio apdorojimo varikliai turi užtikrinti srautinio apdorojimo sistemų plečiamumą [SÇZ05].
- Išskirstytas skaičiavimas (angl. Distributed computation) – tarpusavyje nesusiję skaičiavimo elementai turi naudotojui atrodyti kaip viena darni sistema [TV07]. Srautinio apdorojimo varikliai turi užtikrinti darbų paskirstymą ir skaičiavimo įrenginių koordinaciją, kad kuo daugiau duomenų būtų apdorojami vienu metu [ZGQ⁺17].

Srautinio apdorojimo sistemos turi viena pagrindinį elementą – srauto procesorių (angl. stream processor), kuris apibrėžia sistemos elementus, aprašo kaip šie sistemos elementai sujungti ir pateikia nustatymus elementams [ZGQ⁺17]. Pavyzdžiui, „Apache Storm“ šis elementas vadinamas „topology“, kuris yra užrašomas Java kalba, naudojant „Apache Storm“ pateiktą biblioteką [IS15].

1.1.2. Duomenų priėmimas

Į srautinio apdorojimo sistemą duomenys patenka per šaltinius, kurie šiuos duomenis perduoda tolimesniems elementams. Dažniausiai duomenis perduodami į sistemą naudojant žinučių eiles (angl. message queues), nes jos turi buferį, kuris leidžia mažinti greičių skirtumus tarp duomenų gavimo ir duomenų apdorojimo ir žinučių eilių brokeriai gali išfiltruoti duomenis ir nukreipti juos į tinkamus šaltinius [KF16]. Tačiau šaltiniai turi turėti galimybę rinkti išsaugotus duomenis ir priimti ateinančius naujus duomenis [SÇZ05], todėl, nors ir šaltiniai dažniausiai skirti priimti srautinius duomenis, jie turi taip pat gebėti naudoti duomenis iš talpyklų [ZGQ⁺17].

1.2. Srautinio apdorojimo sistemų matavimas

Svarbiausias srautinio apdorojimo sistemų reikalavimas – duomenų apdorojimas ir rezultatų grąžinimas negali turėti atsilikimo – didelių apimčių srautiniai duomenys turi būti apdorojami taip

pat greitai kaip jie ateina [SÇZ05].

1.2.1. Srautinio apdorojimo sistemų metrikos

Pagrindinės kitų autorių naudojamos metrikos:

- Pralaidumas (angl. Throughput) – per tam tikrą laiko tarpą apdorojamų įvykių kiekis.
- Vėlinimas (angl. Latency) – laiko intervalas nuo apdorojimo arba įvykio pradžios iki apdorojimo pabaigos.

Vėlinimas ir pralaidumas dažniausiai nepriklauso vienas nuo kito – sistemos, apdorojančios srautus mikro–paketais, turi didesnę pralaidumą, tačiau atsiranda papildomas vėlinimas, kol laukiama duomenų paketo apdorojimo pradžios [KRK⁺18].

[SÇZ05] straipsnyje minima, jog srautinio apdorojimo sistemos naudotojas turi išbandyti savo sistemą su tiksliniu darbo krūviu ir išmatuoti jos pralaidumą ir vėlinimą prieš naudodamas ją realiomis sąlygomis. [KRK⁺18] lygina srautinio apdorojimo variklius ir matavimui naudoja vėlinimą, kurį išskaido į įvykio vėlinimą (angl. event–time latency) – laiko intervalas nuo įvykio laiko iki rezultato gavimo iš srautinio apdorojimo sistemos ir apdorojimo vėlinimą (angl. processing–time latency) – laiko intervalas nuo duomens patekimo į srautinio apdorojimo sistemą iki rezultato grąžinimo. Autoriai atlieka šį skaidymą, nes sistemų vertinime dažnai ignoruojamas įvykio laikas ir rezultatuose gaunamas daug mažesnis vėlinimas, nei tikras. Taip pat autoriai išskiria darnų pralaidumą (angl. sustainable throughput) – didžiausia apkrova įvykių, kurią sistema gali apdoroti be pastoviai augančio įvykio vėlinimo, todėl savo eksperimentuose autoriai užtikrina, kad duomenų generavimo greitis atitiktų sistemos darnų pralaidumą. Kad sužinoti darnų pralaidumą sistemos autoriai pradžioje leidžia labai didelį srautą duomenų ir mažina jį kol sistemos apdorojimas susivienodina su generavimo greičiais. Visus vėlinimo rezultatus autoriai pateikia maksimalaus pralaidumo apdorojimo ir 90% pralaidumo apdorojimo vidurkiais, minimumais, maksimumais ir kvantiliais (90, 95, 99). [HSS⁺14] autoriai nagrinėja srautiniam apdorojimui galimas optimizacijas ir matavimui naudoja normalizuotą pralaidumą (naudojamas vienetas kaip vidurkis), kadangi tai leidžia lengviau palyginti santykinę greیتaveiką. Taip pat, [HSS⁺14] pastebi, nors ir yra daug metrikų, kuriomis galima matuoti optimizacijos efektus: pralaidumas, vėlinimas, paslaugos kokybė (angl. quality of service), energijos ir tinklo panaudojimas, tačiau dažniausiai pagerinus pralaidumą pagerėja ir visos kitos metrikos. [QWH⁺16] srautinių apdorojimo sistemų matavimui naudoja pralaidumą (skaičiuojama baitais per sekundę) ir vėlinimą, kaip vidurkį nuo duomens patekimo į sistemą iki apdorojimo pabaigos. Taip pat, kadangi autoriai lygina srautinio apdorojimo variklius,

jie įveda metriką gedimų toleravimo (angl. fault tolerance) matavimui – išjungiamas tam tikras kiekis elementų ir matuojamas pralaidumas ir vėlinimas. [ZYL⁺20] palyginimui naudoja sistemos įvykdymo vėlinimą (angl. system completion latency), kuris rodo vidutinį laiko tarpą per kurį duomuo nukeliauja nuo šaltinio iki sistemos galutinio taško. Autoriai skaičiavo vidutinį laiką 5 sekundžių intervalais. Taip pat autoriai matavimui naudoja kiekvienos instancijos (angl. instance) CPU apkrovą, kiekvieno darbinio mazgo (angl. worker node) CPU apkrovą ir apkrovą tarp instancijų/mazgų, kadangi [ZYL⁺20] užduotis – patobulinti esamą planavimo posistemę. [FAG⁺17] matavimui naudoja pralaidumą per minutę. [VC18] tyria labai panašią problemą – srautinių apdorojimo sistemų balansavimą taikant skatinamąjį mokymą ir matavimui naudoja vėlinimo 99 kvantilį. [CDE⁺16] srautinio apdorojimo variklių vertinimo tyrimui naudoja vėlinimą.

1 lentelė. Metrikos naudojamos tiriant srautinio apdorojimo sistemų greitaveiką

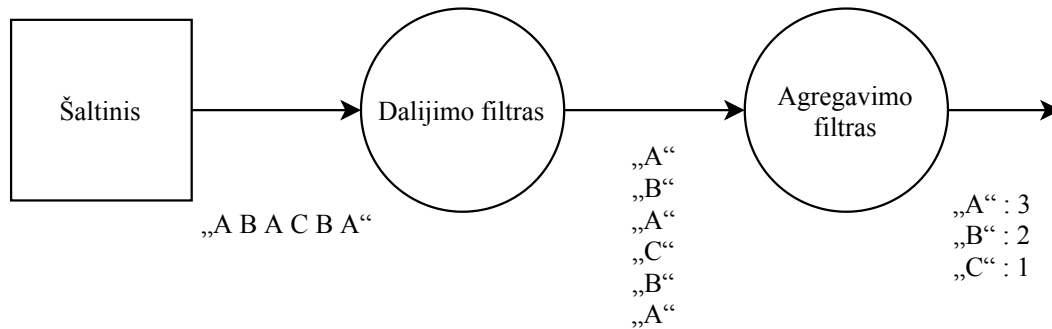
Šaltinis	Vėlinimas	Pralaidumas
[SÇZ05]	Taip	Taip
[KRK ⁺ 18]	Taip	Taip
[HSS ⁺ 14]	Ne	Taip
[QWH ⁺ 16]	Taip	Taip
[ZYL ⁺ 20]	Taip	Ne
[FAG ⁺ 17]	Ne	Taip
[VC18]	Taip	Ne
[CDE ⁺ 16]	Taip	Ne

Pagal literatūros analizę (1 len.) matome, kad dauguma autorių renkasi vertinti tik pagal vieną metriką ir dažniau matavimui naudojamas vėlinimas. Taip pat [VC18], naudojantis skatinamąjį mokymą, matavimui naudoja vėlinimą ir [CDE⁺16] straipsnis, kuris siūlo srautinio apdorojimo sistemų vertinimo sprendimą, naudoja vėlinimą. Todėl magistro darbe matavimui bus naudojamas vėlinimas.

1.2.2. Srautinio apdorojimo sistemos pobūdis


Srautinio apdorojimo sistemos gali turėti skirtingą elementų išsidėstymą ir nuo to priklausys jų greitaveiką. [KRK⁺18] matavimui naudoja du filtrus – agregavimo, kuris skaičiuoja visus pirmus ir jungimo (angl. join), kuris skaičiuoja duomenis pagal tam tikrą bendrą rodiklį iš abiejų duomenų srautų. [QWH⁺16] srautinio apdorojimo variklių palyginimui naudoja septynis skirtingus

uždavinius. Vienas iš jų yra WordCount uždavinys, kuris yra plačiai priimtas kaip didelių duomenų apdorojimo sistemos matavimo standartas [HHD⁺10]. Šis uždavinys susidaro iš dviejų filtrų: pirmas išskaido teksto eilutę į žodžius, o antras agreguoja kiekvieno žodžio bendrą skaitiklį ir atnauja bendrą žodžių panaudojimo dažnio rezultatą, kuriame raktas – žodis, o reikšmė skaičius, kuris rodo kiek kartojosi šis žodis (2 pav.).



2 pav. WordCount sistemos pavyzdys

[ZYL⁺20] matavimui naudoja WordCount sistemą, kuri yra paprastesnė, nei pavaizduota 2 paveikslėlyje, nes šaltinis generuoja ir siunčia tik po vieną žodį ir todėl yra tik agregavimo filtras. Taip pat autoriai naudoja SentenceWordCount sistemą, kuri yra identiška 2 paveikslėlyje pavaizduotai sistemai. Bei autoriai sukūrė FileWordCount sistemą, kuri atlieka tą patį kaip ir SentenceWordCount, tačiau šaltinis negeneruoja žodžius, o skaito iš tekstinio dokumento ir taip pat naudoja egzistuojančią Yahoo srautinio apdorojimo vertinimą (angl. benchmarking) [CDE⁺16]. [FAG⁺17] autoriai naudoja WordCount eksperimentui. [VC18] eksperimentams naudoja Yahoo srautinio apdorojimo variklių vertinimą [CDE⁺16] ir taip pat atlieka bandymus su realiais daiktų internetu (angl. internet of things) įmonės duomenimis. [CDE⁺16] apibrėžia srautinio apdorojimo sistemą skirtingu srautinio apdorojimo variklių vertinimui. Pateikiama sistema analizuoja reklamas pagal kampaniją ir matomumą ir rezultatus deda į Redis duomenų bazę. Sistema sukurta taip, kad aprėptų visas srautinio apdorojimo sistemos savybes (3 pav.).



3 pav. Reklamų analizės sistema [CDE⁺16]

Straipsniai ([FAG⁺17; HHD⁺10; QWH⁺16]) naudoja WordCount (2 pav.), o [CDE⁺16; VC18] naudoja Reklamų analizės srautinę apdorojimo sistemą (3 pav.). Magistro darbe ketinama atlikti tyrimus su Reklamų analizės sistema, kadangi ši sistema sukurta srautinių apdorojimo variklių vertinimui ir su WordCount srautinio apdorojimo sistema, kuri neturi pašalinių elementų sistemoje, kadangi Reklamų analizės sistema naudoja „Apache Kafka“, „Redis“ vertinimui.

1.2.3. Srautinio apdorojimo sistemų matavimo duomenys

Vertinant sistemų greitaveiką reikia atsižvelgti ir į testavimui naudojamus duomenis. [KRK⁺18] naudoja žaidimų kūrimo įmonės Rovio duomenis ir naudoja du duomenų srautus – pirmo srautas, kuriame siunčiami kortežai (angl. tuples) sudaryti iš nupirkto valiutos kiekio, laiko ir naudotojo, kuris ją nupirko ir reklamų srautas, kuris siunčia valiutos reklamas tam tikru laiku. Šiame sprendime duomenis generuojami naudojant normalizuotą paskirstymą ant raktinio lauko. [QWH⁺16] naudoja tekstinius duomenis iš AOL paieškos variklio ir apdoroja juos pagal pasirinktus uždavinius. [ZYL⁺20] matavimui naudoja šaltinių generuojamą tekstą, kadangi lyginamas tas pats srautinio apdorojimo variklis tik su patobulinta planavimo posisteme ir naudoja iš anksto sugeneruotą tekstą patalpintą į tekstinį dokumentą. [CDE⁺16] aprašo sistemą, kuri daro skirtingų srautinio apdorojimo variklių vertinimą. Šiam vertinimui naudojami duomenys simuliuojantys reklamas ir reklamų kampanijas. Autoriai naudoja savo duomenų generatorių. Magistro darbe ketinama naudoti [CDE⁺16] pateikiamą Reklamos analizės sistemos duomenų generatorių, o WordCount srautinės apdorojimo sistemos tyrimui ketinama naudoti WordCount šaltinio generuojamus duomenis.

1.3. Srautinio apdorojimo sistemų derinimas

Sistemų greitaveika yra tiesiogiai susijusi su konfigūravimo parametrais, kurie valdo tokius aspektus kaip: atminties valdymas, gijų skaičius, planavimas, resursų valdymas [LCH⁺19]. Taip pat, neteisingi nustatymai turi nuostolingus efektus sistemos greitaveikai ir stabilumui [HLL⁺11].

[HCL20] išskiria 3 pagrindinius automatinio derinimo iššūkius:

1. Didelė ir sudėtinga parametrų erdvė – „Apache Spark“ ir „Apache Storm“ turi virš 150 konfigūruojamų parametrų [BC17; PGT16]. Taip pat, nustatymų reikšmės, kurios tinka vienam uždaviniui, gali turėti neigiamos įtakos kitam [HLL⁺11; JC16].
2. Sistemų mastas ir sudėtingumas – Sistemų administratoriai turi gebėti konfigūruoti didelius kiekius skaičiavimo mazgų, kurie gali turėti skirtingus CPU, atminties, tinklo tipus [HCL20].
3. Pradinių duomenų statistikos trūkumas – įvedimo duomenys srautinėse apdorojimo sistemose yra realus srautai, kurie stipriai varijuoja savo apimtimi [DP18].

[TLW17] nagrinėjantis tinkamos konfigūracijos radimą naudojant genetinius algoritmus „Apache Storm“ srautinio apdorojimo sistemoms nustatė, jog lygiagretumo laipsnis labiausiai daro įtaką srautinio apdorojimo sistemų greitaveikai. „Apache Heron“ srautinio apdorojimo variklis, kuris yra „Apache Storm“ su patobulinimais [KBF⁺15], pateikia naują būdą kontroliuoti srautą – priešslėgis (angl. backpressure), kuris leidžia filtrui sulėtinti prieš jį einantį elementą, kas leidžia sumažinti vėlinimą ir taip pat gali būti naudojamas kaip greitaveikos praradimo indikatorius [BCB⁺18]. Taip pat [BCB⁺18] nagrinėja „Apache Heron“ automatinį konfigūravimą naudojant iš anksto aprašytas taisykles.

2. Mašininis mokymasis

2.1. Mašininis mokymasis srautinio apdorojimo sistemų derinimui

[HCL20] aprašo skirtingus sprendimus automatiniam konfigūravimui ir išskiria šiuos mašininio mokymosi privalumus:

- Nebūtina suprasti sistemos, užduočių ir duomenų, kadangi naudojamas juodos dėžės (angl. black-box) principas.
- Mašininio mokymosi modelis pats save tobulina, ir yra vis tikslesnis kuo daugiau gauna duomenų.

Šio straipsnio autoriai išskiria mašininio mokymosi iššūkius:

- Parametrų parinkimas – kadangi konfigūruojamų parametrų kiekis yra didelis [BC17; PGT16] ne visi iš jų vienodai daro įtaką greitaveikai, todėl pirma verta išsirinkti aktualiausius parametrus resursų valdymo, užduočių planavimo ir duomenų valdymo užduotims. Tam dažnai naudojama eksperto pagalba [WXH16], gidai arba eksperimentavimas. Tačiau galima naudoti mašininio mokymosi algoritmą koreliacijos nustatymui tarp parametrų ir greitaveikos [YLL⁺12; VC18]
- Mašininio mokymosi modelio pasirinkimas – kadangi yra nemažai skirtingų mašininio mokymosi metodų kurie tinka derinimo uždaviniui.

Taip pat autoriai pateikia paketinio ir srautinio apdorojimo derinimą naudojant mašininį mokymąsi straipsnius (3 lentelėje pateikiami tik išrinkti srautinio apdorojimo pavyzdžiai).

2 lentelė. Srautinių sistemų derinimo naudojant mašininių mokymąsi pavyzdžiai [HCL20]

Šaltinis	Įvesties savybės	Mašininio mokymosi metodai
Zacheilas et al. [ZKZ ⁺ 15]	Rinkinys kelių konfigūracijos parametrų	Gaussian Processes
Li et al. [LTX16]	Atminties dydžiai ir branduolių ir gijų kiekis skirtingose stadijose	Support Vector Regression
Trotter et al. [TLW17]	Darbinių procesų kiekis, vykdytojų kiekis	Genetic Algorithm, Bayesian Optimization
Trotter et al. [TWH19]	Vykdytojai, šaltinių ir filtrų lygiagretumas, acker lygiagretumas	Genetic Algorithm, Support Vector Machines
OrientStream [WMG ⁺ 17]	Įvairios duomenų, plano, filtrų ir klasiterio lygio savybės	Ensemble/ Incremental ML
Vaquero et al. [VC18]	Parametrai ir metrikos parinkti faktoriinės analizės (angl. factor analysis) pagalba	Reinforcement Learning

2.2. Skatinamasis mokymasis srautiniam apdorojimui

[VC18] nagrinėja srautinių sistemų derinimą naudojant skatinamąjį mokymąsi. Autoriai pradžioje pasirenka Lasso path analysis algoritmą, kurio pagalba atlieka parametrų atranka, kad išrinktų svarbiausius parametrus pasirinktos metrikos valdymui. Konfigūracijos valdymui pasirinktas modifikuotas REINFORCE algoritmas. Atliktas eksperimentas su „Apache Spark“, kuris rodo 60–70% sumažintą vėlinimą.

[NLY⁺19] nagrinėja resursų valdymo problemą srautinio apdorojimo sistemose ir siūlo sprendimą naudojanči skatinamąjį mokymą, kuris daro optimizacijas pagal srautinės apdorojimo sistemos grafus. Eksperimentas atliekamas naudojant REINFORCE [Wil92] algoritmą su Adam optimizacijos funkcija [KB14] ir atliekamas eksperimentas naudojant tyrimui parašytą srautinio apdorojimo variklį ir sistemas.

[LXT⁺18] nagrinėja planavimo problemos (apkrovos paskirstymas darbiniais elemen-

tams) sprendimą naudojant skatinamąjį mokymąsi. Autoriai siūlo naudoti Actor–Critic illic-
rap2015continuous metodą naudojant Deep Q Learning [MKS⁺15] tinklą kaip Actor ir bet koki
gilųjį neuroninį tinklą kaip Critic. Autorių rezultatai rodo 45% greیتaveikos padidėjimą lyginant su
integruota „Apache Storm“ planavimo posisteme.

[RCP19] nagrinėja srautinių sistemų dislokavimą naudojant skatinamąjį mokymą. Spen-
džiama problema dislokavimo valdymo su skirtingais skaičiavimo mazgų tipais. Naudojamas Q
Learning algoritmas su įvairioms modifikacijom (kombinuojama su tiksliais modeliais). Autoriai
matuoja dislokavimo tikslumą ir konvergavimo greitį.

3 lentelė. Skatinamojo mokymosi naudojimas

Šaltinis	Skatinamojo mokymosi algoritmas
[VC18]	Adaptuotas REINFORCE [Wil92]
[NLY ⁺ 19]	REINFORCE [Wil92] su Adam optimizacijos funkcija [KB14]
[LXT ⁺ 18]	Deep Q Learning [MKS ⁺ 15] ir Actor–Critic [LHP ⁺ 15]
[RCP19]	Q–learning [MKS ⁺ 15] su papildomomis funkcijomis

Išvados

1. Išnagrinėjus literatūrą nustatyta, kad:

- matavimui tinka Reklamos analizės sistema, kadangi ji yra sukurta ir naudojama kaip vertinimo standartas srautinio apdorojimo varikliams, ir WordCount sistema, kadangi ji neturi pašalinių elementų, kurie gali sukurti trukdžius ir yra naudojama kitų autorių moksliniuose darbuose.
- duomenų generavimui tinka naudoti [CDE⁺16] duomenų generatorių Reklamos analizės sistemos bandymui, kuris yra pateikiamas kartu su srautinio apdorojimo variklių vertinimu ir WordCount šaltinio duomenų generatorių WordCount eksperimentams.
- sprendimų greitaveikos vertinimui tinka naudoti vėlinimą, kadangi [CDE⁺16] naudoja vėlinimą srautinio apdorojimo variklių vertinimui bei kiti autoriai naudoja vėlinimą siūlomų sprendimų greitaveikos įrodymui.

2. Deep Q Learning ir Actor–Critic algoritmai yra tinkami skatinamojo mokymosi algoritmai srautinio apdorojimo sistemų derinimui, atsižvelgus į jų naujumą ir tinkamumą nagrinėti pastovaus valdymo uždavinius [SLH⁺14]. Taip pat atsižvelgus į [HCL20; VC18] rezultatus yra rekomenduojama atlikti bandymus su sumažinta konfigūruojamų elementų aibe naudojant parametrų parinkimą, atlikti bandymus su nekeista elementų aibe ir palyginti rezultatus.

Literatūra

- [BBD⁺02] Brian Babcock, Shivnath Babu, Mayur Datar, Rajeev Motwani ir Jennifer Widom. Models and issues in data stream systems. *Proceedings of the twenty-first ACM SIGMOD-SIGACT-SIGART symposium on Principles of database systems*, p. 1–16, 2002.
- [BC17] Muhammad Bilal ir Marco Canini. Towards automatic parameter tuning of stream processing systems. P. 189–200, 2017-09. DOI: 10.1145/3127479.3127492.
- [BCB⁺18] Manu Bansal, Eyal Cidon, Arjun Balasingam, Aditya Gudipati, Christos Kozyrakis ir Sachin Katti. Trevor: automatic configuration and scaling of stream processing pipelines, 2018. arXiv: 1812.09442 [cs.DC].
- [Bea15] Jonathan Beard. A short intro to stream processing. <http://www.jonathanbeard.io/blog/2015/09/19/streaming-and-dataflow.html>, 2015-09.
- [Bon00] André B Bondi. Characteristics of scalability and their impact on performance. *Proceedings of the 2nd international workshop on Software and performance*, p. 195–203, 2000.
- [CDE⁺16] S. Chintapalli, D. Dagit, B. Evans, R. Farivar ir k.t. Benchmarking streaming computation engines: storm, flink and spark streaming. *2016 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW)*, p. 1789–1792, 2016.
- [DP18] Miyuru Dayarathna ir Srinath Perera. Recent advancements in event processing. *ACM Comput. Surv.*, 51(2), 2018-02. ISSN: 0360-0300. DOI: 10.1145/3170432.
- [FA17] Avrielia Floratou ir Ashvin Agrawal. Self-regulating streaming systems: challenges and opportunities. *Proceedings of the International Workshop on Real-Time Business Intelligence and Analytics, BIRTE '17*, 1:1–1:5, Munich, Germany. ACM, 2017. ISBN: 978-1-4503-5425-7. DOI: 10.1145/3129292.3129295. URL: <http://doi.acm.org/10.1145/3129292.3129295>.
- [FAG⁺17] Avrielia Floratou, Ashvin Agrawal, Bill Graham, Sriram Rao ir Karthik Ramasamy. Dhalion: self-regulating stream processing in heron. *Proceedings of the VLDB Endowment*, 10:1825–1836, 2017-08. DOI: 10.14778/3137765.3137786.
- [FY11] Zbynek Falt ir Jakub Yaghob. Task scheduling in data stream processing. *DATESO*, p. 85–96, 2011.

- [HCL20] Herodotos Herodotou, Yuxing Chen ir Jiaheng Lu. A survey on automatic parameter tuning for big data processing systems. *ACM Computing Surveys (CSUR)*, 53(2):1–37, 2020.
- [Her19] Heron. Heron documentation on cluster configuration. <http://heron.incubator.apache.org/docs/cluster-config-overview/>, 2019.
- [HHD⁺10] Shengsheng Huang, Jie Huang, Jinquan Dai, Tao Xie ir Bo Huang. The hibenx benchmark suite: characterization of the mapreduce-based data analysis. *2010 IEEE 26th International Conference on Data Engineering Workshops (ICDEW 2010)*, p. 41–51. IEEE, 2010.
- [HLL⁺11] Herodotos Herodotou, Harold Lim, Gang Luo, Nedyalko Borisov, Liang Dong, Fatma Bilgen Cetin ir Shivnath Babu. Starfish: a self-tuning system for big data analytics. *Cidr*, tom. 11 numeris 2011, p. 261–272, 2011.
- [HSS⁺14] Martin Hirzel, Robert Soulé, Scott Schneider, Buğra Gedik ir Robert Grimm. A catalog of stream processing optimizations. *ACM Computing Surveys (CSUR)*, 46(4):1–34, 2014.
- [YLL⁺12] Hailong Yang, Zhongzhi Luan, Wenjun Li, Depei Qian ir Gang Guan. Statistics-based workload modeling for mapreduce. *2012 IEEE 26th International Parallel and Distributed Processing Symposium Workshops & PhD Forum*, p. 2043–2051. IEEE, 2012.
- [IS15] Muhammad Hussain Iqbal ir Tariq Rahim Soomro. Big data analysis: apache storm perspective. *International journal of computer trends and technology*, 19(1):9–14, 2015.
- [JC16] Pooyan Jamshidi ir Giuliano Casale. An uncertainty-aware approach to optimal configuration of stream processing systems. *CoRR*, abs/1606.06543, 2016. eprint: 1606.06543.
- [JOA10] Thomas Jaksch, Ronald Ortner ir Peter Auer. Near-optimal regret bounds for reinforcement learning. *J. Mach. Learn. Res.*, 11:1563–1600, 2010-08. issn: 1532-4435. URL: <http://dl.acm.org/citation.cfm?id=1756006.1859902>.
- [KB14] Diederik P. Kingma ir Jimmy Ba. Adam: a method for stochastic optimization, 2014. arXiv: 1412.6980 [cs.LG].

- [KBF⁺15] Sanjeev Kulkarni, Nikunj Bhagat, Maosong Fu, Vikas Kedigehalli, Christopher Kellogg, Sailesh Mittal, Jignesh M. Patel, Karthik Ramasamy ir Siddarth Taneja. Twitter heron: stream processing at scale. *Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data*, SIGMOD '15, p. 239–250, Melbourne, Victoria, Australia. ACM, 2015. ISBN: 978-1-4503-2758-9. DOI: 10.1145/2723372.2742788. URL: <http://doi.acm.org/10.1145/2723372.2742788>.
- [KF16] Supun Kamburugamuve ir Geoffrey Fox. Survey of distributed stream processing. *Bloomington: Indiana University*, 2016.
- [KKW⁺15] Holden Karau, Andy Konwinski, Patrick Wendell ir Matei Zaharia. *Learning spark: lightning-fast big data analysis*. ” O'Reilly Media, Inc.”, 2015.
- [KRK⁺18] Jeyhun Karimov, Tilmann Rabl, Asterios Katsifodimos, Roman Samarev, Henri Heiskanen ir Volker Markl. Benchmarking distributed stream processing engines. *ArXiv*, abs/1802.08496, 2018.
- [LCH⁺19] Jiaheng Lu, Yuxing Chen, Herodotos Herodotou ir Shivnath Babu. Speedup your analytics: automatic parameter tuning for databases and big data systems. *Proceedings of the VLDB Endowment*, 12(12):1970–1973, 2019.
- [LHP⁺15] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver ir Daan Wierstra. Continuous control with deep reinforcement learning, 2015. arXiv: 1509.02971 [cs.LG].
- [LTX16] Teng Li, Jian Tang ir Jielong Xu. Performance modeling and predictive scheduling for distributed stream data processing. *IEEE Transactions on Big Data*, 2(4):353–364, 2016.
- [LXT⁺18] Teng Li, Zhiyuan Xu, Jian Tang ir Yanzhi Wang. Model-free control for distributed stream data processing using deep reinforcement learning. *Proc. VLDB Endow.*, 11(6):705–718, 2018-02. ISSN: 2150-8097. DOI: 10.14778/3199517.3199521. URL: <https://doi.org/10.14778/3199517.3199521>.
- [MKS⁺15] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu ir k.t. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.

- [NLY⁺19] Xiang Ni, Jing Li, Mo Yu, Wang Zhou ir Kun-Lung Wu. Generalizable resource allocation in stream processing via deep reinforcement learning, 2019. arXiv: 1911.08517 [cs.LG].
- [NPP⁺17] Shadi A Noghabi, Kartik Paramasivam, Yi Pan, Navina Ramesh, Jon Bringham, Indranil Gupta ir Roy H Campbell. Samza: stateful scalable stream processing at linkedin. *Proceedings of the VLDB Endowment*, 10(12):1634–1645, 2017.
- [PGT16] Panagiotis Petridis, Anastasios Gounaris ir Jordi Torres. Spark parameter tuning via trial-and-error, 2016. arXiv: 1607.07348 [cs.DC].
- [QWH⁺16] S. Qian, G. Wu, J. Huang ir T. Das. Benchmarking modern distributed streaming platforms. *2016 IEEE International Conference on Industrial Technology (ICIT)*, p. 592–598, 2016.
- [Ram16] Karthik Ramasamy. Open sourcing twitter heron, 2016.
- [RCP19] Gabriele Russo Russo, Valeria Cardellini ir Francesco Lo Presti. Reinforcement learning based policies for elastic stream processing on heterogeneous resources. *Proceedings of the 13th ACM International Conference on Distributed and Event-Based Systems, DEBS '19*, p. 31–42, Darmstadt, Germany. Association for Computing Machinery, 2019. ISBN: 9781450367943. DOI: 10.1145/3328905.3329506. URL: <https://doi.org/10.1145/3328905.3329506>.
- [RM19] Henriette Röger ir Ruben Mayer. A comprehensive survey on parallelization and elasticity in stream processing. *ACM Computing Surveys (CSUR)*, 52(2):1–37, 2019.
- [SÇZ05] Michael Stonebraker, Uğur Çetintemel ir Stan Zdonik. The 8 requirements of real-time stream processing. *ACM Sigmod Record*, 34(4):42–47, 2005.
- [SLH⁺14] David Silver, Guy Lever, Nicolas Heess, Thomas Degris, Daan Wierstra ir Martin Riedmiller. Deterministic policy gradient algorithms. *Proceedings of the 31st International Conference on International Conference on Machine Learning - Volume 32, ICML'14*, p. I–387–I–395, Beijing, China. JMLR.org, 2014.
- [SSP04] David G. Sullivan, Margo I. Seltzer ir Avi Pfeffer. Using probabilistic reasoning to automate software tuning. *SIGMETRICS Perform. Eval. Rev.*, 32(1):404–405, 2004–06. ISSN: 0163-5999. DOI: 10.1145/1012888.1005739. URL: <http://doi.acm.org/10.1145/1012888.1005739>.

- [Ste97] Robert Stephens. A survey of stream processing. *Acta Informatica*, 34(7):491–541, 1997.
- [TLW17] M. Trotter, G. Liu ir T. Wood. Into the storm: descrying optimal configurations using genetic algorithms and bayesian optimization. *2017 IEEE 2nd International Workshops on Foundations and Applications of Self* Systems (FAS*W)*, p. 175–180, 2017.
- [TV07] Andrew S Tanenbaum ir Maarten Van Steen. *Distributed systems: principles and paradigms*. Prentice-Hall, 2007.
- [TWH19] Michael Trotter, Timothy Wood ir Jinho Hwang. Forecasting a storm: divining optimal configurations using genetic algorithms and supervised learning. *2019 IEEE International Conference on Autonomic Computing (ICAC)*, p. 136–146. IEEE, 2019.
- [VC18] Luis M. Vaquero ir Felix Cuadrado. Auto-tuning distributed stream processing systems using reinforcement learning, 2018. arXiv: 1809.05495 [cs.DC].
- [Wil92] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine learning*, 8(3-4):229–256, 1992.
- [WMG⁺17] Chunkai Wang, Xiaofeng Meng, Qi Guo, Zujian Weng ir Chen Yang. Automating characterization deployment in distributed data stream management systems. *IEEE Transactions on Knowledge and Data Engineering*, 29(12):2669–2681, 2017.
- [WXH16] Guolu Wang, Jungang Xu ir Ben He. A novel method for tuning configuration parameters of spark based on machine learning. *2016 IEEE 18th International Conference on High Performance Computing and Communications; IEEE 14th International Conference on Smart City; IEEE 2nd International Conference on Data Science and Systems (HPCC/SmartCity/DSS)*, p. 586–593. IEEE, 2016.
- [ZGQ⁺17] Xinwei Zhao, Saurabh Garg, Carlos Queiroz ir Rajkumar Buyya. A taxonomy and survey of stream processing systems. *Software Architecture for Big Data and the Cloud*, p. 183–206. Elsevier, 2017.
- [ZYL⁺20] Yitian Zhang, Jiong Yu, Liang Lu, Ziyang Li ir Zhao Meng. L-heron: an open-source load-aware online scheduler for apache heron. *Journal of Systems Architecture*, 106:101727, 2020.
- [ZKZ⁺15] Nikos Zacheilas, Vana Kalogeraki, Nikolas Zygouras, Nikolaos Panagiotou ir Dimitrios Gunopulos. Elastic complex event processing exploiting prediction. *2015 IEEE International Conference on Big Data (Big Data)*, p. 213–222. IEEE, 2015.